

Felipe Meneguitti Dias

Engenharia de IA aplicada à saúde

Desenvolvo modelos e sistemas de IA para saúde. No InCor, liderei o Gorgona e coordenei a anotação de cerca de 20 mil ECGs por 19 cardiologistas. Hoje sou especialista sênior de P&D na Samsung e doutor pela USP.

Projetos selecionados

Gorgona

Classificação de ECGs de UPAs, com envio ao InCor e alertas pelo Telegram em paralelo à telemedicina. Liderei o projeto e o desenvolvimento inicial da integração.

42.037 registros processados na plataforma, na consulta de 03/10/2026.

ECG na emergência do InCor

Classificação de ECGs integrada ao PACS e à aplicação da emergência. Desenvolvi modelos, coordenei a anotação clínica e participei da implantação e avaliação.

Cerca de 20 mil ECGs na iniciativa de anotação com 19 cardiologistas.

RPMS

Monitoramento remoto com relógios, processamento de PPG no celular e painel médico. Desenvolvi protocolos de coleta, pré-processamento e algoritmos com a equipe.

52 voluntários e 15 pulseiras na versão publicada em 2022.

Samsung · 2026–atual | InCor · 2020–2026

f.meneguittidias@gmail.com

fmenegui.com · [LinkedIn](#) · [Currículo](#)

Gorgona

Classificação de ECGs integrada ao atendimento de urgência

Objetivo

Antecipar a identificação de ECGs com suspeita de corrente de lesão e comunicar esses exames à equipe de regulação. A análise automática ocorre em paralelo à telemedicina. A avaliação do paciente e a decisão assistencial permanecem com a equipe médica.

Responsabilidade no projeto


Conectei o modelo de classificação ao cliente Windows, ao processamento no InCor, ao painel web e ao envio de alertas. A equipe clínica conduziu o protocolo assistencial e a avaliação dos exames.

Fluxo anterior

Envio manual à telemedicina e comunicação da equipe com a regulação, conforme a avaliação médica.

Com o Gorgona

Cliente Windows, anonimização configurável, servidor InCor e alerta automático pelo Telegram.



Fluxo proposto com IA. Figura original do projeto.

A telemedicina e a decisão clínica permanecem no fluxo. HTTPS e credenciais por instalação complementam a anonimização local configurável.

Operação e estudo de caso

42.037

registros processados

2 min

do ECG ao alerta, no caso


41 min

antes do primeiro laudo

Consulta de 03/10/2026: todas as unidades, período completo, status Processado, classes Corrente de Lesão e Outros. A contagem corresponde a registros de exames, não a pacientes únicos.

UPA Rodrigo Argolo · 20/05/2026

Em 20 de maio de 2026, um atendimento na UPA Rodrigo Argolo permitiu acompanhar o fluxo completo. A admissão ocorreu às 18h52. Os dois ECGs geraram alertas automáticos 2 minutos após sua realização. A chegada ao centro de referência foi registrada às 20h44.



Trecho da linha do tempo original do estudo de caso, slide 23. O recorte omite o bloco de identificação pessoal e começa no primeiro ECG. Admissão: 18h52.

O primeiro alerta chegou 4 minutos antes de o ECG entrar na telemedicina. A antecedência em relação aos laudos foi de 41 e 25 minutos. O caso demonstra a antecipação da informação à regulação. Não permite atribuir à IA uma redução no tempo até o tratamento ou nos desfechos clínicos.

Base científica do modelo

O classificador foi desenvolvido a partir do modelo da equipe AIMED vencedor da tarefa de classificação do PhysioNet Challenge 2024. O artigo do CinC 2024 e minha tese documentam essa base científica.

Referências

[Image-Based Electrocardiogram Classification Using Pre-trained ConvNext](#) · Computing in Cardiology, 2024.

[Classificação automatizada de imagens de eletrocardiogramas por aprendizado profundo](#) · Universidade de São Paulo · Tese de doutorado, 2025.

[Image-based deep learning for emergency electrocardiogram classification](#) · medRxiv · Preprint, 2026.

[Mapa da UPA, cliente Windows e plataforma online no estudo completo](#)

ECG na emergência do InCor

Do PACS à tela da equipe médica

Objetivo

Apoiar a priorização da revisão médica dos ECGs na emergência, levando a classificação automática ao ambiente de trabalho da equipe assistencial.

Responsabilidade no projeto

Desenvolvi e implantei modelos de classificação de ECGs na emergência. Coordenei a anotação de aproximadamente 20 mil exames por 19 cardiologistas, com definição de classes, adjudicação e análise de concordância, além da avaliação pós-implantação e da comparação com especialistas.




Figura 1 do artigo de Dias et al., IEEE Access (2023). Integração proposta entre aquisição do ECG, DICOM/PACS, classificador e aplicação web na emergência. Imagem fornecida pelo autor.

Resultados e avaliação

A arquitetura de 2023 apresenta três classes: fibrilação atrial, outros e normal. A linha de pesquisa evoluiu para um ensemble ConvNeXt com 12 categorias. O estudo de 2026 reúne 18.519 ECGs de 14.402 pacientes e obteve macro F1 de 0,807 no teste reservado (IC 95%: 0,788 a 0,825).

A implantação incluiu avaliação por cardiologista e comparação com especialistas. O tamanho da base de pesquisa não representa o volume de exames processados em rotina.

Referências

[Artificial Intelligence-Driven Screening System for Rapid Image-Based Classification of 12-Lead ECG Exams: A Promising Solution for Emergency Room Prioritization](#) · IEEE Access, 2023.

[Image-based deep learning for emergency electrocardiogram classification](#) · medRxiv · Preprint, 2026.

[Classificação automatizada de imagens de eletrocardiogramas por aprendizado profundo](#) · Universidade de São Paulo · Tese de doutorado, 2025.

RPMS


Remote Patient Monitoring System

Objetivo

Permitir o acompanhamento de pacientes fora do hospital, conectando sinais coletados por dispositivos vestíveis a biomarcadores disponíveis para a equipe médica.

Responsabilidade no projeto

Minha atuação reuniu protocolos de coleta com relógios protótipos, organização dos dados, pré-processamento de sinais de fotopletismografia (PPG) e desenvolvimento de algoritmos em equipe.



Arquitetura publicada em Moreno, Dias et al. (SIoT, 2022), Figura 1. O processamento ocorre no celular.

O relógio envia o PPG ao aplicativo Android por Bluetooth Low Energy. O celular processa o sinal, estima pressão arterial e frequência cardíaca e envia os resultados por MQTT ao servidor ThingsBoard. O painel permite acompanhar as medidas de cada paciente ao longo do tempo.

52 voluntários e 15 pulseiras na versão publicada em 2022.

Validação e pesquisa

O protocolo publicado separa participantes entre as partições de validação. A implementação de 2022 estima pressão e frequência cardíaca. Qualidade do sinal, diabetes e sono são frentes de pesquisa documentadas nos artigos abaixo.

Referências

- [IoT Medical Device Architecture to Estimate Non-invasive Arterial Blood Pressure](#) · Symposium on Internet of Things (SIoT), 2022.
- [Quality Assessment of Photoplethysmography Signals For Cardiovascular Biomarkers Monitoring Using Wearable Devices](#) · arXiv · Preprint, 2023.
- [Exploring the limitations of blood pressure estimation using the photoplethysmography signal](#) · Physiological Measurement, 2025.
- [Machine Learning-Based Diabetes Detection Using Photoplethysmography Signal Features](#) · SBCAS, 2024.
- [Enhancing Photoplethysmography-Based Sleep Staging Models Through Temporal Context Optimization](#) · Studies in Health Technology and Informatics, 2025.